

SLIC算法学习报告

超像素生成算法简介

SLIC算法流程及复现思路

SLIC算法优点及创新点总结

超像素生成算法简介

超像素算法**将像素组合成感知有意义的原子区域**，其可以用于替换像素网格的刚性结构。它们捕获图像冗余，提供计算图像特征的方便原语，并且大大降低了后续图像处理任务的复杂性。

目前存在许多产生超像素的方法，每种具有其自身的优点和缺点，可更好地适合于特定应用，大致分类为基于图或梯度上升的方法。



图：使用SLIC分割成尺寸(大约)为64，256和1024的超像素结果

| | | |
|-----------------|---------------------------|-----------------|
| 超像素生成算法衡量指标 | 良好的超像素生成算法需具备的特点 | SLIC表现 |
| 图像边界的粘附性 | 超像素应当良好地粘附到图像边界 | 对图像边界有良好的粘附性 |
| 算法速度与存储效率 | 计算速度快，存储器效率高且易于使用 | 比现有算法快，有更高的存储效率 |
| 对分割性能的影响 | 当用于分割目的时，超像素应当增加速度并提高结果质量 | 分割效果优于现有算法 |
| 是否能够控制超像素生成个数 | 是 | 是 |
| 是否能够控制超像素生成的复杂度 | 是 | 是 |
| 是否易于扩展到更高维 | 是 | 是 |

| | GS04 [8] | NC05 [23] | Graph-based | | | WS91 [28] | Gradient-ascent-based | | | SLIC |
|--|---------------------|------------------|--------------|----------------------------|----------------------------|--------------|-----------------------|---------------------------|--------------|---------------|
| | | | SL08 [21] | GCa10 ^b [26] | GCb10 ^b [26] | | MS02 [4] | TP09 ^b [15] | QS09 [25] | |
| Adherence to boundaries | | | | | | | | | | |
| Under-segmentation error (rank) | 0.23 | 0.22 | - | 0.22 | 0.22 | - | - | 0.24 | 0.20 | 0.19 |
| Boundary recall (rank) | 0.84 | 0.68 | - | 0.69 | 0.70 | - | - | 0.61 | 0.79 | 0.82 |
| Segmentation speed | | | | | | | | | | |
| 320 × 240 image | 1.08s ^a | 178.15s | - | 5.30s | 4.12s | - | - | 8.10s | 4.66s | 0.36s |
| 2048 × 1536 image | 90.95s ^a | N/A ^c | - | 315s | 235s | - | - | 800s | 181s | 14.94s |
| Segmentation accuracy (using [11] on MSRC) | 74.6% | 75.9% | - | - | 73.2% | - | - | 62.0% | 75.1% | 76.9% |
| Control over amount of superpixels | No | Yes | Yes | Yes | Yes | No | No | Yes | No | Yes |
| Control over superpixel compactness | No | No | No | No ^d | No ^d | No | No | No | No | Yes |
| Supervoxel extension | No | No | No | Yes | Yes | Yes | No | No | No | Yes |

SLIC算法流程

Algorithm 1 SLIC superpixel segmentation

/ Initialization */*

Initialize cluster centers $C_k = [l_k, a_k, b_k, x_k, y_k]^T$ by sampling pixels at regular grid steps S .

Move cluster centers to the lowest gradient position in a 3×3 neighborhood.

Set label $l(i) = -1$ for each pixel i .

Set distance $d(i) = \infty$ for each pixel i .

repeat

/ Assignment */*

for each cluster center C_k **do**

for each pixel i in a $2S \times 2S$ region around C_k **do**

Compute the distance D between C_k and i .

if $D < d(i)$ **then**

set $d(i) = D$

set $l(i) = k$

end if

end for

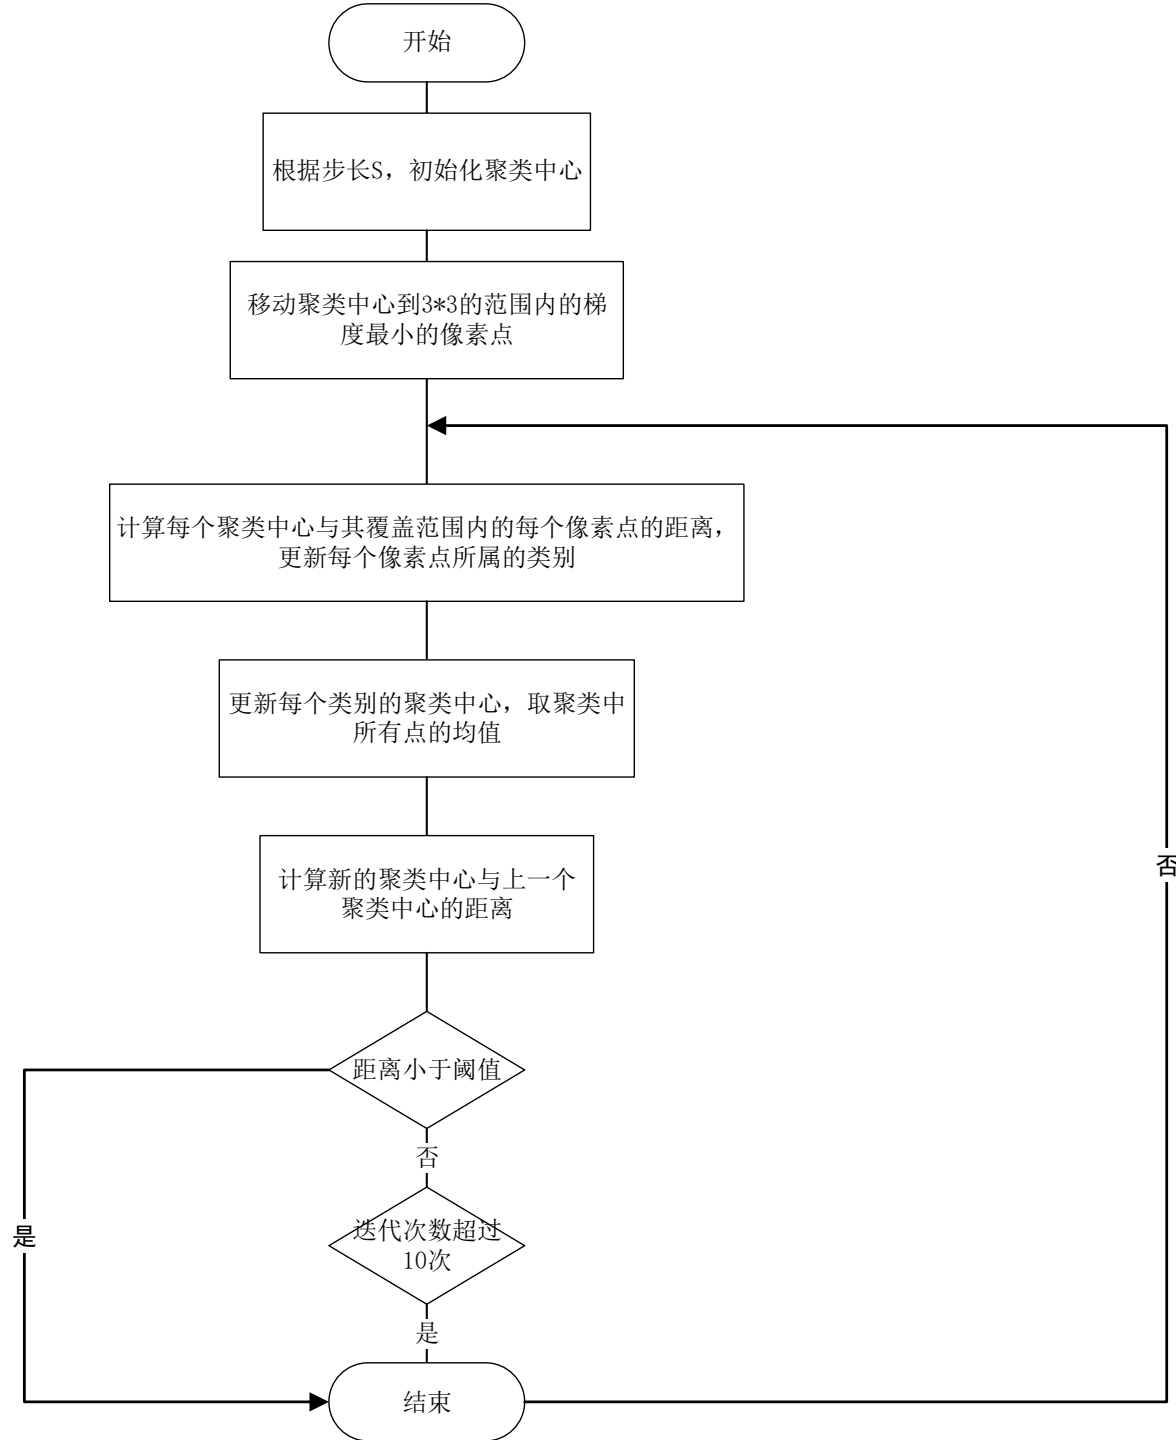
end for

/ Update */*

Compute new cluster centers.

Compute residual error E .

until $E \leq \text{threshold}$



| | |
|------------|---|
| Class SLIC | |
| img | 图像数据，由rgb读入，转为lab |
| height | 图像高度 |
| width | 图像宽度 |
| N | 图像像素个数，height*width |
| S | 初始化聚类中心采样间隔及限制聚类中心搜索空间的参数， $\sqrt{\frac{N}{K}}$ |
| K | 聚类个数 |
| M | 权衡颜色相似性和空间邻近度之间相对重要性的参数，用于计算像素间的距离 |
| cluster | 聚类中心，数据类型为list，每个元素为自定义的Cluster类 |
| label | 每个像素点所属的聚类中心，数据类型为dict |
| dis | 各个像素点与其最近聚类中心的距离，numpy创建的二维数组，初始化为np.inf |

为实现SLIC算法，定义的两个Class

| | |
|---------------|--------------------|
| Class Cluster | |
| num | 聚类中心的编号 |
| x、y | 聚类中心的位置 |
| l、a、b | 聚类中心的图像信息 |
| point | 该类包含的像素点，数据类型为list |

```
if __name__ == '__main__':  
    slic = SLIC("lenna.jpg", 500, 30)  
    slic = initCluster(slic)  
    slic = moveCluster(slic)  
    slicProcessing(slic)
```

复现代码主要流程

```
def slicProcessing(slic):  
    for i in range(10):  
        slic_old = copy.deepcopy(slic)  
        slic = labelAssign(slic)  
        slic = updateCluster(slic)  
        e = getE(slic_old, slic)  
        print("iter " + str(i) + " error:", e)  
        saveImage(slic, 'image' + str(i) + ".png")  
        if e <= 1:  
            break
```

主要函数说明：

| | |
|-----------------|---|
| initCluster() | 初始化聚类中心，间隔步长S取样 |
| moveCluster() | 将初始化完成的聚类中心，在3*3范围内调整到梯度最小的点处，尽可能避免聚类中心为边缘点 |
| getGradient() | 计算一个像素点的梯度，(x,y)点与(x+1,y+1)点的I、a、b差值之和，如果(x+1,y+1)点超出范围，则取(x-1,y-1)点 |
| labelAssign() | 遍历所有的聚类中心，在计算聚类中心覆盖范围内的点与该中心的距离nowdis，如果now_dis小于该点的dis数组中记录的值，则将该点的聚类中心修改为当前遍历的中心，并将该点添加到该中心的point中，同时将原聚类中心中的信息删掉 |
| updateCluster() | 新的label确认后，在每个聚类中心中重新计算向量的平均值，修改聚类中心向量 |
| getE() | 计算两次迭代的聚类中心向量的距离 |
| saveImage() | 将同一个类别的点都采用其聚类中心的颜色信息表示，保存聚类结果 |
| getDistance() | 计算两个向量之间的距离（颜色和空间信息加权） |

SLIC的优点

1. 限制减少迭代时的计算量。

传统的k-means在更新时需要比较每个数据点与k个聚类中心的距离，进行所属类别的划分，时间复杂度为 $O(KN)$ ，SLIC限制了聚类的范围，只需要搜索聚类中心一定范围内的数据点与该中心的距离，进行所属类别更新，时间复杂度变为 $O(N)$ ，显著地减少了距离计算的数量。

2. 加权度量颜色和空间位置接近度，同时提供对超像素的尺寸和紧凑性的控制。

$$\begin{aligned}d_c &= \sqrt{(l_j - l_i)^2 + (a_j - a_i)^2 + (b_j - b_i)^2} \\d_s &= \sqrt{(x_j - x_i)^2 + (y_j - y_i)^2} \\D' &= \sqrt{\left(\frac{d_c}{N_c}\right)^2 + \left(\frac{d_s}{N_s}\right)^2}.\end{aligned}$$

如果将两个点之间的距离简单定义为二维欧式空间，则在不同大小的超像素中，距离差距的影响不同，导致聚类的过程中行为不一致，所以需要对距离和颜色差异做标准化，分别计算差距后，除以各自的最大的值，距离标准化的参数 N_s 即为采样间隔 S ，颜色的标准化参数 N_c 定义为常数 m ，实际试验中取 $[1, 40]$ 范围内的值。

当 m 较大时，空间邻近性更为重要，所得到的超像素更加紧凑（超像素面积小，面积周长比大）， m 较小时，颜色距离权重更大，所得的超像素更加紧密地粘附到图像边界。

加权距离度量方式，使得该方法可以控制结果中对图像边界的粘附性，超像素生成的复杂度等。



M=30



M=5

通过结果可以看出，M值的变化对于超像素生成结果有较大影响，M较大时，超像素面积小，更加紧凑，M较小时，所得结果更加粘附到图像边界。

SLIC的优点

3. 良好的扩展性，易于处理灰度图像和3D超体素。
4. 参数只有K和M，算法流程清晰，易实现。